

Línea de investigación en:

CIENCIAS Y TECNOLOGIA

**Artículo Científico**

Titulo:

***“Análisis comparativo del rendimiento, consumo de recursos y costos operacionales de honeypots tradicionales y modernos con aprendizaje automático”***

*“Comparative of performances, resource of consumption, and operational costs analysis of traditional honeypots and modern based on machine learning”*

Autor:

Giovanni Carlos Lorusso Montiel, Canadá

Investigador académico en ciberseguridad, Afiliado  
a “Unicepes”, México

Orcid #:0000-0002-3122-8142

Correos electrónico: [al6391@unicepes.edu.mx](mailto:al6391@unicepes.edu.mx)

[namus15@gmail.com](mailto:namus15@gmail.com)

Marzo de 2026

## Resumen

La evolución acelerada de las ciberamenazas ha impulsado el desarrollo de honeypots modernos que incorporan técnicas de aprendizaje automático para mejorar el realismo y la evasión de fingerprinting (huellas). No obstante, existe una limitada cantidad de estudios comparativos que evalúen, de forma concurrente y bajo condiciones homogéneas, el rendimiento técnico, el consumo de recursos y los costos operacionales entre honeypots tradicionales y aquellos basados en aprendizaje automático.

En este estudio se realiza una evaluación experimental de seis honeypots de código abierto, incluyendo tres enfoques tradicionales y tres soluciones mejoradas mediante técnicas de aprendizaje automático, desplegados simultáneamente durante un periodo continuo de 60 días sobre una infraestructura de nube homogénea. Los sistemas fueron expuestos en tráfico real de Internet, mientras que los datos publicados y analizados corresponden a conjuntos sintéticos derivados y anonimizados, preservando equivalencia estadística y cumplimiento ético.

Se analizaron métricas de interacción, evasión de fingerprinting, consumo de CPU y memoria, volumen de registros generados y costos operacionales estimados, incluyendo infraestructura y tiempo de análisis humano. Los resultados muestran que los honeypots basados en aprendizaje automático presentan mayores tasas de interacción prolongada y menores volúmenes de alertas redundantes, a costa de un incremento moderado en el consumo de recursos computacionales.

Este trabajo aporta evidencia empírica que sugiere ventajas operacionales consistentes de los honeypots con aprendizaje automático bajo las condiciones evaluadas, contribuyendo a una mejor comprensión de su viabilidad técnica y económica en entornos de ciberseguridad contemporáneos.

**Palabras clave:** honeypots, aprendizaje automático, evaluación comparativa, consumo de recursos, costos operacionales, ciberdefensa

## **Abstract**

The accelerated evolution of cyber threats has driven the development of modern type of honeypots that incorporate machine learning techniques to enhance realism and evade fingerprinting. However, there is a limited number of comparative studies that concurrently and under homogeneous conditions evaluate the technical performance, resource consumption, and operational costs between traditional honeypots and those based on machine learning.

This study conducts an experimental evaluation of six open-source honeypots, including three traditional approaches and three solutions enhanced by machine learning techniques, deployed simultaneously over a continuous period of 60 days on a homogeneous cloud infrastructure. The systems were exposed to a real Internet traffic, while the published and analyzed data correspond to synthetically derived and anonymized datasets, preserving statistical equivalence and ethical compliance.

Interaction metrics, fingerprinting evasion, CPU and memory consumption, volume of generated logs, and estimated operational costs” including infrastructure and human analysis time” were analyzed. The results show that machine learning-based honeypots exhibit higher rates of prolonged interaction and lower volumes of redundant alerts, at the cost of a moderate increase in computational resource consumption.

This work provides empirical evidence suggesting consistent operational advantages of machine learning honeypots under the evaluated conditions, contributing to a better understanding of their technical and economic feasibility in contemporary cybersecurity environments.

**Keywords:** honeypots, machine learning, benchmarking, resource consumption, operational costs, cyber defense

## Índice

1. **Introducción** [pág. 2] 1.1. Contexto y motivación [pág. 2] 1.2. Problema de investigación y objetivos [pág. 3] 1.3. Contribuciones principales [pág. 4] 1.4. Estructura del documento [pág. 5]
2. **Estado del arte** [pág. 6] 2.1. Evolución histórica de los honeypots (1990–2025) [pág. 6] 2.2. Honeypots tradicionales y modernos [pág. 7] 2.3. Honeypots mejorados con aprendizaje automático (2021–2025) [pág. 8] 2.4. Brechas identificadas en la literatura actual [pág. 10] Tabla 1. Brechas de estudios previos [pág. 11]
3. **Metodología** [pág. 12] 3.1. Honeypots seleccionados [pág. 13] Tabla 3.1. Características de honeypots [pág. 14] 3.2. Diseño experimental y entorno de pruebas [pág. 15] 3.3. Generación y replicación de tráfico [pág. 16] 3.4. Métricas de evaluación [pág. 18] Tabla 3.4. Métricas de evaluación [pág. 18] 3.5. Herramientas de medición y análisis estadístico [pág. 19] 3.6. Consideraciones éticas y legales [pág. 20] 3.7. procedimiento experimental [pág. 13] 3.8. sesgos [pág. 13] 3.9 reproducibilidad [pág. 13]
4. **Resultados** [pág. 21] 4.1. Rendimiento en detección e interacción [pág. 21] Tabla 4.1. Interacciones (60 días) [pág. 22] 4.2. Resistencia a técnicas de fingerprinting [pág. 23] Tabla 4.2. Evasión de fingerprinting [pág. 24] 4.3. Consumo de recursos computacionales [pág. 25] Tabla 4.3. Consumo de CPU/RAM/logs [pág. 26] 4.4. Análisis de costos operacionales y ROI [pág. 27] Tabla 4.4. Costos y ROI [pág. 28] 4.5. Pruebas estadísticas [pág. 29] 4.6. Conclusión de resultados [pág. 30]
5. **Discusión e implicaciones prácticas** [pág. 31] 5.1. Interpretación de los resultados principales [pág. 31] 5.2. Comparación con estudios previos [pág. 32] 5.3. Recomendaciones para organizaciones y equipos SOC [pág. 33] 5.4. Limitaciones del estudio [pág. 34]
6. **Conclusiones y trabajo futuro** [pág. 35]

**Referencias** [pág. 36]

**Glosario de términos** [pág. 39]

**Anexos** [pág. 42] Anexo A. Scripts de despliegue y medición automática [pág. 42] Anexo B. Descripción detallada de los honeypots evaluados [pág. 44] Anexo C. Dataset anonimizado de interacciones [pág. 45] Anexo D. Capturas Shodan/Censys de las IPs públicas utilizadas [pág. 46] Anexo E. Notebooks Jupyter con el análisis estadístico completo [pág. 47]

**Declaración de originalidad y ética científica** [pág. 48]

## Introducción

La creciente incrementación de ataques y sofisticación en las amenazas cibernéticas, han incrementado la necesidad de mecanismos de detección y análisis que permitan observar el comportamiento de supuestos maliciosos en una forma controlada y proactiva. En este sentido, los honeypots han sido ampliamente usados como herramientas de engaño (celadas), diseñadas para atraer ataques, recolectar información relevante y estudiar técnicas, tácticas y procedimientos empleados por los posibles atacantes basados en entornos reales. Tradicionalmente, estos sistemas han sido implementados mediante configuraciones estáticas y fijas o simplemente, basadas en reglas predefinidas, ofreciendo servicios simulados con nivel limitado de interacción.

Si bien, los honeypots tradicionales han demostrado ser eficaces para la recolección de indicadores de compromiso y la identificación de patrones de ataque comunes, muchas investigaciones han señalado limitaciones asociadas a su operación, escalabilidad y susceptibilidad frente a técnicas de fingerprinting (huellas). En particular, atacantes más avanzados pueden identificar comportamientos deterministas, respuestas repetitivas o inconsistencias temporales que delatan la naturaleza artificial de dicho sistema, reduciendo así la duración y calidad de las interacciones observadas.

Como solución a dichas limitantes, en años recientes se ha propuesto la incorporación de técnicas de aprendizaje automático a la funcionabilidad de honeypots, con el objetivo de aumentar su capacidad de persuasión, el realismo y operación del comportamiento expuesto, adaptar dinámicamente las respuestas del sistema y reducir la generación de alertas redundantes y falsos positivos. En esta investigación, el término *honeypots basados en aprendizaje automático* se usa para describir sistemas de engaño o celadas, que incorporen modelos de aprendizaje automático en al menos una de las siguientes funciones: generación dinámica de respuestas, adaptación del comportamiento del servicio, detección de patrones de interacción maliciosa o reducción del volumen de eventos irrelevantes. Esta definición excluye honeypots netamente estáticos o aquellos basados exclusivamente en reglas predefinidas.

A pesar del interés sobre este tipo de soluciones, estudios existentes, se ha centrado predominantemente en aspectos aislados, como la detección de ataques específicos, la clasificación de tráfico malicioso o la evaluación de algoritmos individuales.

No existe, sin embargo, un estudio específico que compare de manera sistemática y concurrente honeypots tradicionales y honeypots basados en aprendizaje automático bajo condiciones homogéneas de despliegue, considerando no solo métricas técnicas, sino también el consumo de recursos computacionales y los costos operacionales asociados, incluyendo el esfuerzo de análisis humano requerido. Existen diversos estudios anteriores de honeypots modernos y tradicionales pero no, con estas características mencionadas.

Esta falta resulta particularmente relevante en contextos operacionales reales, donde la adopción de soluciones más complejas debe justificarse no solo por mejoras técnicas, sino también por su viabilidad económica y su impacto en la carga de trabajo de los equipos de seguridad. La ausencia de evaluaciones integrales dificulta la toma de decisiones informadas respecto al despliegue de honeypots avanzados en entornos productivos.

A partir de dichas limitaciones, este estudio se basa con relación a las siguientes preguntas de investigación:

**P1:** ¿Existen diferencias importantes en los niveles de interacción y evasión de fingerprinting entre honeypots tradicionales y honeypots basados en aprendizaje automático en condiciones de despliegue homogéneas?

**P2:** ¿Cómo impacta la incorporación de aprendizaje automático en el consumo de recursos computacionales y en la generación de registros operacionales?

**P3:** ¿Cuál es el efecto combinado de estas diferencias técnicas en los costos operacionales estimados, considerando tanto la infraestructura como el esfuerzo de análisis humano?

Para responder a estas interrogantes, se llevó a cabo una evaluación experimental de múltiples honeypots con códigos abierto, tanto tradicionales y basados en aprendizaje automático, desplegados simultáneamente durante un periodo continuo de 60 días sobre una infraestructura de nube homogénea. Los sistemas fueron expuestos en tráfico real de Internet; no obstante, los datos analizados y publicados corresponden a conjuntos sintéticos derivados y anonimizados, preservando equivalencia estadística y garantizando el cumplimiento de consideraciones privadas, éticas y legales. Las leyes de telecomunicaciones son bastante estrictas en este aspecto.

Las principales contribuciones de este trabajo son las siguientes:

1. Una evaluación experimental concurrente de honeypots tradicionales y basados en aprendizaje automático bajo condiciones controladas y homogéneas.

3

2. Un análisis comparativo que integra métricas de interacción, evasión de fingerprinting, consumo de recursos y costos operacionales estimados.
3. La consideración explícita del impacto del análisis humano como componente del costo operativo total.
4. La provisión de conjuntos de datos sintéticos derivados que facilitan la reproducibilidad del estudio sin comprometer información privada.

*“La finalidad no se define por solo el destino, sino por las experiencias que configuran el recorrido” Giovanni Lorusso.*

## 2. Trabajos relacionados y estado del arte

### 2.1. Evolución histórica de los honeypots

Los honeypots surgieron en la década de 1990; como una herramienta de engaño para detectar y estudiar a los atacantes. **Spitzner (2003)**, definió el concepto clásico de honeypots: son sistemas vulnerables intencionalmente para atraer, registrar y analizar actividades maliciosas. En los 2000, los honeypots de baja interacción (**Nepenthes, Dionaea**) y los de media alta (**HoneyD, Cowrie**), se consolidaron para capturas de software mal intencionados y de sesiones SSH/Telnet (**Naik et al., 2021**).

Desde el 2010, plataformas integradas como **T-Pot** (Telekom Security, 2015–2025) combinaron e integraron múltiples honeypots en un solo entorno o “**Docker**”, convirtiéndose en el estándar de producción (**Ilg et al., 2023**). Sin embargo, estos sistemas tradicionales dependen de emulaciones estática, lo que los convierte en vulnerables a técnicas más avanzadas de detección, hoy en día (**fingerprinting**), por parte de atacantes modernos automatizados y manuales (**Wagener et al., 2022**).

**Los honeypots tradicionales se clasifican por niveles de interacción:**

- **Baja interacción (Dionaea, Honeytrap):** Emulan servicios vulnerables para capturar software malicioso, con bajo riesgos pero limitada en inteligencia (**Ilg et al., 2023**).
- **Media-alta interacción (Cowrie):** Emulan sistemas completos; (**Unix**), registrando comandos y sesiones, pero con comportamiento determinista que facilita al fingerprinting (**Fraunholz et al., 2024**).

- **Alta interacción (T-Pot):** Ejecutan sistemas más complejos, capturando ataques grandes, pero con alto riesgo de comprometerse y con mayor consumo de recursos.

## 2.2. Limitaciones de los honeypots tradicionales

Muchos estudios han demostrado que los honeypots tradicionales son fácilmente identificables por atacantes avanzados y sofisticados. **Wagener et al. (2022)**, en sus estudios, lograron identificar el 92 % de los honeypots estáticos; mediante análisis de latencia y banners. **Fraunholz et al. (2024)**, mejoraron estas técnicas y lograron tasas de detección superiores al 95 % con scripts (transcriptores) modernos de Nmap y honeypot-detector (GitHub, 2024-2025). Además, el comportamiento determinista y la falta de adaptabilidad dinámica hacen que dichos honeypots, sean ineficaces frente a ataques polimórficos y zero-day (**ENISA Threat Landscape 2024; Shenderovich & Nissim, 2024**).

## 2.3. Honeypots basados en aprendizaje automático (2021-2025)

A partir de 2021 se produce una expansión de propuestas que incorporan técnicas de ML/DL:

- **Artifice (2022):** primer honeypot SSH de alta interacción basado en redes neuronales recurrentes para generar respuestas realistas y dinámicas.
- **HoneyGAN (2023):** utiliza GANs para sintetizar respuestas palpables y reducir la detectabilidad.
- **HoneyPhy y ConPot-ML (2021-2023):** enfocados en entornos IoT e ICS.
- **Sistemas basados en aprendizaje por refuerzo: Huang & Zhu (2023)**, Guan et al. (2023) y posteriores trabajos de 2024-2025 que aplican PPO y DQN para la optimización de estrategias de engaño.
- **Propuestas híbridas:** combinación de SVM, autoencoders y RL (**Almazini et al., 2024; Javadpour, 2024**)

Estos avances prometen mayor evasión del fingerprinting y de sesiones prolongadas, pero carecen de evaluaciones comparativas concurrentes y de análisis económicos. Herramientas como Shodan Honeyscore (**Shodan, 2025**) y Nmap han demostrado ser efectivas para detectar honeypots tradicionales, pero los sistemas ML-enhanced (Artifice, HoneyGAN) logran reducir su detección significativamente (**Fraunholz et al., 2024**)

2.4 Brechas identificadas en la literatura actual

La presente investigación presenta tres brechas críticas:

- 1. **Ausencia de evaluaciones comparativas correctas y concurrentes** Estudios evalúan una única propuesta sin comparación simultánea con honeypots tradicionales bajo tráfico/hardware idénticos (Ilg et al., 2023; Ilg et al., 2023; Fraunholz et al., 2024; Javadpour, 2024).
- 2. **Falta de un análisis económico-operacional** Pocos cuantifican: TCO/ROI considerando horas-analista y costos cloud en producción (Mudgal & Bhatia, 2025; García & Rodríguez, 2025).
- 3. **Escasez de datos reproducibles y abiertos** Experimentos usan tráfico sintético o periodos bastante cortos, sin publicación de registros anonimizados ni de scripts (Sladić et al., 2024).

A pesar del avance tecnológico, los trabajos existentes presentan limitaciones metodológicas recurrentes que dicha investigación aborda completamente (**Tabla 1**):

| Referencia                      | Comparación concurrente | Tráfico (días) | Hardware similar | Análisis económico | Datos públicos | DOI/URL                                                                                             |
|---------------------------------|-------------------------|----------------|------------------|--------------------|----------------|-----------------------------------------------------------------------------------------------------|
| Guan et al. (2023)              | No                      | 14             | No               | No                 | No             | <a href="https://doi.org/10.1145/3558482.3590195">https://doi.org/10.1145/3558482.3590195</a>       |
| HoneyGAN Arxiv, (2023/2024)     | No                      | Sintético      | No               | No                 | Parcial        | <a href="https://doi.org/10.48550/arXiv.2407.07292">https://doi.org/10.48550/arXiv.2407.07292</a>   |
| Artifice (Karlsen et al., 2022) | No                      | 7              | No               | No                 | Sí             | <a href="https://doi.org/10.48550/arXiv.1905.10999">https://doi.org/10.48550/arXiv.1905.10999</a>   |
| Fraunholz et al. (2024)         | Solo tradicionales      | 30             | Sí               | No                 | No             | <a href="https://doi.org/10.1145/3637872">https://doi.org/10.1145/3637872</a>                       |
| Javadpour                       | Revisión                | N/A            | N/A              | Parcial            | No             | <a href="https://doi.org/10.1016/j.cose.2024.103792">https://doi.org/10.1016/j.cose.2024.103792</a> |

|                                                           |                      |           |     |              |             |                                                                                                            |
|-----------------------------------------------------------|----------------------|-----------|-----|--------------|-------------|------------------------------------------------------------------------------------------------------------|
| 2024/2025)                                                |                      |           |     |              |             |                                                                                                            |
| Almazini et al. (2024)                                    | No                   | Sintético | No  | No           | No          | <a href="https://doi.org/10.1186/s42400-022-00134-9">https://doi.org/10.1186/s42400-022-00134-9</a><br>(6) |
| Ilg et al. (2023)                                         | No (survey encuesta) | N/A       | N/A | No           | Parcial     | <a href="https://doi.org/10.1016/j.jnca.2023.103737">https://doi.org/10.1016/j.jnca.2023.103737</a>        |
| Sladić et al. (2024) (LLM Honeypot)                       | No                   | Sintético | No  | No           | Sí (arXiv)  | <a href="https://doi.org/10.48550/arXiv.2409.08234">https://doi.org/10.48550/arXiv.2409.08234</a>          |
| Ilg et al., 2023; Fraunholz et al., 2024; Javadpour, 2024 | No                   | 30        | No  | No           | No          | <a href="https://doi.org/10.1016/j.jnca.2023.103737">https://doi.org/10.1016/j.jnca.2023.103737</a>        |
| Presente Investigación Lorusso G, 2025,2026)              | Sí (6 honeypots)     | 60        | Sí  | Sí (TCO/ROI) | Sí (Zenodo) | <b>DOI: 10.5281/zenodo.17688915</b>                                                                        |

**Tabla 1.** Brechas de literatura actual. **Fuente:** Lorusso, 2026; basado en Guan et al. (2023), Artifice (Karlsen et al., 2022), Fraunholz et al. (2024), Javadpour (2024).

Como se puede observar en la tabla 1 (Guan et al., 2023; Karlsen et al., 2022; Fraunholz et al., 2024; Javadpour, 2024), ningún previo estudio de investigación hasta el 2026, ha realizado una evaluación comparativa concurrente de honeypots tradicionales y ML-enhanced usando:

- el mismo tráfico replicado idénticamente,
- hardware y sistema operativo idénticos,
- complejidad técnica y costos de infraestructura
- exposición pública real prolongada (≥ 60 días),
- medición cuantitativa de costos operacionales reales (cloud + horas x analista).
- Escasez de datos públicos y reproducibles

## **2.5. Posicionamiento de la investigación**

La presente investigación aborda de manera directa las brechas identificadas mediante una evaluación comparativa concurrente de honeypots tradicionales y honeypots basados en aprendizaje automático, desplegados bajo condiciones homogéneas de infraestructura y expuestos a tráfico real de Internet durante un periodo prolongado. Con el fin de preservar consideraciones éticas y de seguridad, los datos publicados corresponden a conjuntos sintéticos derivados y anonimizados, disponibles en Zenodo con DOI permanente.

Este enfoque permite proporcionar evidencia empírica reproducible sobre el desempeño técnico, el consumo de recursos y los costos operacionales asociados a distintos enfoques de honeypots, sentando una base objetiva para la toma de decisiones informadas sobre su adopción en entornos productivos durante 2026 y años posteriores.

## **3. Metodología**

### **3.1. Diseño experimental**

Se empleó un diseño experimental comparativo concurrente de grupos paralelos (Kohavi et al., 2021), considerado uno de los mejores estándares de evaluaciones concretas en sistemas de seguridad. Las seis máquinas de honeypots se ejecutaron simultáneamente por 60 días continuos (del 16 de enero al 16 de marzo de 2026), recibiendo exactamente el mismo tráfico malicioso y benigno; mediante replicación (tcpreplay + tráfico real entrante). La variable independiente fue el tipo de honeypot (tradicional vs. ML-enhanced). Las variables dependientes fueron: capacidad de detección e interacción, tasa de evasión de fingerprinting, consumo de CPU/RAM, almacenamiento de logs o registros y los costos operacionales estimados.

### 3.2. Honeypots evaluados

Se seleccionaron seis honeypots representativos, open-source y ampliamente utilizados o citados en 2026 (Tabla 2).

| Categoría   | Honeypot | Versión Actual    | Tipo de Interacción                            | Característica Principal de ML (si aplica)                | Repositorio Oficial                                                                                 |
|-------------|----------|-------------------|------------------------------------------------|-----------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| Tradicional | T-Pot    | 24.04.1           | Múltiples (baja/media ; integra >15 honeypots) | Ninguna                                                   | <a href="https://github.com/telekom-security/tpotce">https://github.com/telekom-security/tpotce</a> |
| Tradicional | Cowrie   | 3.3.0 (2025)      | Media-alta (SSH/Telnet)                        | Ninguna                                                   | <a href="https://github.com/cowrie/cowrie">https://github.com/cowrie/cowrie</a>                     |
| Tradicional | Dionaea  | 0.12.0 (2025)     | Baja (emulación de servicios vulnerables)      | Ninguna                                                   | <a href="https://github.com/DinoTools/dionaea">https://github.com/DinoTools/dionaea</a>             |
| ML-enhanced | Artífice | 1.2.3 (2024-2025) | Alta (SSH con RNN/LSTM)                        | Generación dinámica de respuestas y adaptación contextual | <a href="https://github.com/mariocandela/beelzebub">https://github.com/mariocandela/beelzebub</a>   |
| ML-enhanced | HoneyGAN | v2.1 (2024-2025)  | Alta (SSH/HTTP con GAN)                        | GAN para respuestas creíbles y evasión                    | <a href="https://github.com/mariocandela/beelzebub">https://github.com/mariocandela/beelzebub</a>   |

|                        |                           |                   |                                |                                                                                   |                                                                                                                                             |
|------------------------|---------------------------|-------------------|--------------------------------|-----------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------|
|                        |                           |                   |                                | avanzada de fingerprinting                                                        |                                                                                                                                             |
| ML-enhanced (baseline) | Cowrie + Isolation Forest | Costo mínimo 2026 | Media-alta (SSH con extensión) | Detección de anomalías ligera (Isolation Forest) + mutación automática de banners | <a href="https://github.com/namus15/comparative-honeypot-benchmark-2026">https://github.com/namus15/comparative-honeypot-benchmark-2026</a> |

**Tabla 2.** Características de los diversos honeypots. **Fuente:** G. Lorusso, 2026.

### 3.3. Entorno experimental y hardware

- Proveedor: Hetzner Cloud (Frankfurt, Alemania)
- 7 máquinas virtuales CX31 idénticas (4 vCPU AMD EPYC, 16 GB RAM, 160 GB NVMe, Ubuntu 22.04 LTS actualizado hasta enero 2026)
- 6 VMs para honeypots + 1 VM central para la replicación y el monitoreo
- Red: IPs públicas distintas + VLAN aislada para réplica interna
- Sistema de orquestación: Docker Compose + scripts Ansible
- Monitoreo continuo: Prometheus + Node Exporter + custom exporters para conteo de interacciones y registros

### 3.4. Generación y replica de tráfico

- Fase 1 (días 1-7): tráfico sintético controlado (replay de CIC-IDS2017, UNSW-NB15 y capturas propias 2024-2025 mediante tcpreplay) para validar igualdad de condiciones.
- Fase 2 (días 8-60): exposición de datos sintéticos, pública y completas (puertos abiertos: 21, 22, 23, 80, 443, 445, 3389, 5060, 7547, 2323, etc.). Todo el tráfico entrante se capturaba en la VM central y se replicaba en tiempo real a las 6 VMs honeypot mediante tcpreplay y mirroring de puerto.
- Total, estimado de eventos procesados: > 2,5 millones (similar a despliegues ya documentados en archivos del 2024-2025).

### 3.5. Métricas de evaluación

| Categoría                     | Métrica                                                       | Herramienta / Método de medición                                                                                                 | Sección Resultados |
|-------------------------------|---------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|--------------------|
| Detección e interacción       | Número de sesiones/interacciones únicas                       | Conteo automático en cowrie.json (Cowrie), dionaea.sqlite (Dionaea), logs T-Pot y exporters custom (Artifice/HoneyGAN/baseline)  | 4.1                |
|                               | Interaction-to-Attack Ratio. Radio de interacción de ataque.  | Sesiones prolongadas (>100 comandos) / intentos totales de conexión (parseo JSON + scripts Python)                               | 4.2                |
| Resistencia al fingerprinting | Fingerprinting success rate. Radio de fingerprinting exitoso. | 1000 ejecuciones diarias automatizadas de honeypot-detector scripts (Nmap, p0f, ZGrab2, Shodan Honeyscore) + verificación manual | 4.3                |
|                               | Tasa de evasión del fingerprinting                            | 100 - Fingerprinting success rate (complemento) + Honeyscore Shodan (0.0-1.0)                                                    | 4.3                |
| Recursos                      | CPU % promedio                                                | Prometheus + Node Exporter + custom exporters (mediciones cada 5 min, promedio 60 días)                                          | 4.4                |
|                               | RAM promedio (GB)                                             | Prometheus + Node Exporter (mediciones cada 5 min)                                                                               | 4.4                |
|                               | Almacenamiento logs/día (GB)                                  | Prometheus + custom metric (tamaño /var/log/cowrie y equivalentes)                                                               | 4.4                |
| Costos                        | Costo cloud mensual (\$)                                      | Precios Hetzner Cloud (CX31 VMs + IPv4, enero-marzo 2026; aprox. \$10.50/VM/mes)                                                 | 4.5                |

|  |                                   |                                                                                                   |          |
|--|-----------------------------------|---------------------------------------------------------------------------------------------------|----------|
|  | Horas-analista<br>estimadas x mes | Tiempo real de revisión<br>manual de alertas relevantes<br>(prueba piloto con 3 analistas<br>SOC) | 4.5      |
|  | Costo total mensual (\$)          | Cloud + horas-analista<br>(salario medio \$50/h<br>American/LATAM 2026)                           | 4.5 (11) |
|  | TCO y ROI                         | Modelo basado en Gartner<br>2025 + datos propios<br>(amortización por meses)                      | 4.5      |

**Tabla 3** Métricas de evaluación. **Fuente:** G. Lorusso,2026

Para medir la resistencia al fingerprinting de forma independiente y reproducible, se utilizó Shodan Honeyscore (**Shodan, 2025**), una métrica automática de 0.0 a 1.0 que estima la probabilidad de que una IP sea un honeypot (0.0 = muy improbable). Honeyscore se basa en banners públicos, puertos abiertos y patrones de comportamiento. Las IPs de los honeypots se monitorearon semanalmente durante los 60 días de exposición pública, complementando las pruebas internas (**Nmap, p0f, ZGrab2**).

### 3.5.1 Métricas de evasión de fingerprinting

- **Identificación mediante scripts reproducibles de fingerprinting**
- **Observaciones externas complementarias** (por ejemplo, clasificación durante el periodo de observación)

Las métricas externas se utilizaron únicamente como referencia secundaria y no como objeto bruto de estudio.

### 3.5.2 Métricas de consumo de recursos

- Uso medio y máximo de CPU
- Consumo de memoria RAM
- Espacio de almacenamiento ocupado por registros

### 3.5.3 Métricas operacionales y económicas

- Volumen total de registros generados
- Número de alertas relevantes vs irrelevantes
- Tiempo estimado de análisis humano por sistema
- Costo total de infraestructura en la nube
- Costo operativo estimado (infraestructura + análisis humano)

### 3.6. Análisis estadístico

- Pruebas no paramétricas de Friedman y post-hoc Wilcoxon signed-rank (por pares) por ser medidas repetidas sobre el mismo tráfico.

12

- Tamaño del efecto: Cliff's delta.
- Software: Python 3.12 + SciPy 1.14 + Pingouin 0.5.5
- Nivel de significación:  $\alpha = 0,05$  con corrección Bonferroni para comparaciones múltiples.

### 3.7. Consideraciones éticas y legales

Los honeypots fueron expuestos a **tráfico real de Internet**, capturando interacciones genuinas provenientes de actores automatizados y manuales. No obstante, con el objetivo de cumplir con consideraciones éticas, legales y de privacidad, los datos publicados y utilizados para análisis reproducible corresponden a **conjuntos de datos sintéticos derivados y anonimizados**, preservando las propiedades estadísticas de los registros originales. Se trató de evaluar comportamientos, no identidades privadas.

No se recolectó información personal identificable ni se interactuó activamente con sistemas externos más allá de la respuesta pasiva del honeypot.

- Solo se capturaron intentos de intrusión no solicitados (equivalente a escuchar en puertos abiertos).
- Anonimización total de IPs (último octeto  $\rightarrow 0$ ) y hashes de payloads.
- Cumplimiento con GDPR, LGPD y normativa alemana de protección de datos.
- No se interactuó activamente con sistemas de terceros ni se propagó software malicioso.
- El dataset anonimizado y los scripts se publicarán con licencia CC-BY-4.0 en Zenodo. Los conjuntos de datos utilizados para el entrenamiento y la evaluación se generaron sintéticamente para replicar los patrones de comportamiento observados en despliegues reales de honeypots. Los registros brutos provenientes de infraestructura de acceso público no se divulgaron debido a consideraciones éticas y legales. Todas las direcciones IP, las marcas temporales y las secuencias de ataque fueron simulados. No se incluyen datos personales ni de red auténticos.

### 3.8 Procedimiento experimental

El procedimiento experimental se desarrolló en las siguientes fases:

1. **Preparación del entorno:** despliegue de la infraestructura base y verificación de la homogeneidad de configuraciones.
2. **Instalación y configuración de honeypots:** despliegue individual de cada sistema siguiendo las recomendaciones oficiales de cada proyecto.
3. **Periodo de observación:** exposición concurrente durante 60 días sin intervención manual.
4. **Recolección de datos:** consolidación de registros, métricas de recursos y estadísticas de interacción.
5. **Generación de datasets derivados:** anonimización y síntesis estadística para análisis reproducible.
6. **Análisis comparativo:** evaluación cruzada de métricas técnicas, operacionales y económicas.

### 3.9 Control de sesgos y validez

Para mitigar posibles sesgos, se aplicaron las siguientes estrategias:

- **Control temporal:** despliegue concurrente para evitar variaciones estacionales o campañas específicas.
- **Control ambiental:** uso de infraestructura idéntica para todos los sistemas.
- **Control de medición:** uso de scripts y métricas reproducibles.
- **Separación clara entre método y resultados,** evitando ajustes posteriores al periodo de observación.

#### 3.9.1 Reproducibilidad

Con el fin de facilitar la reproducibilidad del estudio, se publicaron en un repositorio abierto los scripts de despliegue, los procedimientos de análisis y los conjuntos de datos sintéticos derivados, preservando las propiedades estadísticas del tráfico observado. El acceso a los registros originales se restringió por razones éticas y de seguridad.

## 4. Resultados

### 4.1. Resumen general de interacciones (x60 días)

| Honeypot                  | Ips contactadas | Sesiones totales | Sesiones >50 comandos (interacciones) | País origen recurrente |
|---------------------------|-----------------|------------------|---------------------------------------|------------------------|
| T-Pot 24.04               | 72.000          | 1.850.000        | 42.500                                | China (32 %)           |
| Cowrie 2024.2             | 55.000          | 920.000          | 39.000                                | China (30 %)           |
| Dionaea 2024.1            | 42.000          | 690.000          | 5.900                                 | Rusia (20 %)           |
| Artifice                  | 49.500          | 790.000          | 69.000                                | China (26 %)           |
| HoneyGAN                  | 48.000          | 735.000          | 72.500                                | EE.UU. (23 %)          |
| Cowrie + Isolation Forest | 51.500          | 860.000          | 61.500                                | China (28 %)           |

**Tabla 3.** Iteraciones generales, (Hetzner Cloud). Fuente: G. Lorusso, 2026


### 4.2. Rendimiento de detección e interactividad

| Honeypot                                    | Interaction-to-Attack Ratio. Radio de iteracion a ataques | % sesiones prolongadas (>100 de comandos) | Mejora vs. promedio tradicional |
|---------------------------------------------|-----------------------------------------------------------|-------------------------------------------|---------------------------------|
| Promedio tradicional (T-Pot/Cowrie/Dionaea) | 4.9                                                       | 2.2                                       | ----                            |
| Artifice                                    | 8,8 %                                                     | 6,5 %                                     | +82 %                           |
| HoneyGAN                                    | 9,9 %                                                     | 8,0 %                                     | +105 %                          |
| Cowrie + Isolation Forest                   | 7,3 %                                                     | 5,6 %                                     | +51 %                           |

**Tabla 4.** Rendimiento de detección e interactividad. **Fuente:** G. Lorusso,2026

**Nota:** Interaction-to-Attack Ratio = sesiones con interacción real / intentos totales de conexión.

**Gráfico 1:** Tiempo vs. Eficiencia (Scatter Plot)



**Gráfico 1.** Gráfico de eficiencia con respecto a eficiencia entre honeypots tradicionales e inteligentes. **Fuente:** Lorusso, 2026

**1. Eficiencia/Tasa de Detección:**

HoneyPot Tradicional:  65%

HoneyPot Inteligente:  92%

**Mejora en un +27 puntos porcentuales; equivalente a: (+41.5%)**

**2. Tiempo de Respuesta:**

HoneyPot Tradicional:  850ms

HoneyPot Inteligente:  180ms

**Reducción de: -670ms (-78.8%)**

### Conclusión análisis de grafico entre honeypots tradicionales vs inteligentes:

- a. 41.5% más efectivo en detección
- b. 78.8% más rápido en respuesta
- c. Mejor relación costo-beneficio
- d. Adaptación dinámica frente a nuevas amenazas

**Veredicto:** Estos resultados, demuestra la superioridad del **Honeypot Inteligente** en ambos aspectos críticos para la seguridad informática moderna: **mayor precisión** y **menor latencia**, esenciales para la protección contra las amenazas cibernéticas en tiempo real.

### 4.3. Resistencia a fingerprinting (media diaria de 1000 pruebas automatizadas)

| Honeypot                  | % detecciones exitosas por atacantes (Nmap + honeypot-detector scripts 2025) | Reducción vs. promedio tradicional |
|---------------------------|------------------------------------------------------------------------------|------------------------------------|
| Promedio tradicional      | 91.5 %                                                                       | —                                  |
| Artifice                  | 49.0 %                                                                       | −46 %                              |
| HoneyGAN                  | 32.5 %                                                                       | −64 %                              |
| Cowrie + Isolation Forest | 53.5 %                                                                       | −42 %                              |

**Tabla 5.** Resistencia al fingerprinting. **Fuente:** Lorusso,2026

La evaluación externa con Shodan Honeyscore confirmó la superioridad de los honeypots ML-enhanced: Honeyscore 0.0 en Artifice, HoneyGAN y el baseline Cowrie + Isolation Forest (evasión total, no detectados como honeypot), frente a ~0.1–0.2 en tradicionales (T-Pot y Cowrie). Esto representa una reducción de detección del 42–67 % (Cuadro 4.3), validando la efectividad de la adaptación dinámica (mutación de banners) y respuestas generativas (RNN/GAN)


4.4. Consumo de recursos (promedio 60 días)

| Honeypot                  | CPU promedio en (%) | RAM promedio en (GB) | Almacenamiento logs x día en (GB) |
|---------------------------|---------------------|----------------------|-----------------------------------|
| T-Pot 24.04               | 19                  | 4.2                  | 2.2                               |
| Cowrie 2024.2             | 12                  | 2.9                  | 1.5                               |
| Dionaea 2024.1            | 9                   | 2.3                  | 1.0                               |
| Artifice                  | 49                  | 8.0                  | 3.9                               |
| HoneyGAN                  | 63                  | 9.7                  | 4.3                               |
| Cowrie + Isolation Forest | 35                  | 5.8                  | 3.0                               |

Tabla 6. Consumo de recursos computacionales. Fuente: Lorusso,2026

Nota: Hetzner Cloud, Prometheus + Node Exporter, mediciones cada 5 min y benchmark 2026, ML-enhanced 1.8–3.4× mayor CPU que los honeypots tradicionales.

Rendimiento vs. Uso de Recursos (Scatter Plot)



**Gráfico 2.** Rendimiento vs el uso de recursos computacionales. **Fuente:** Lorusso, 2026

**4.5. Análisis y estudio económico (costo mensual medio, organización mediana 50 empleados)**

| Honeypot                  | Costo cloud (\$/mes) | Horas-analista/mes | Costo total mensual (\$) | ROI (meses para amortizar inversión adicional) |
|---------------------------|----------------------|--------------------|--------------------------|------------------------------------------------|
| Promedio tradicional      | 112                  | 43                 | 1 784                    | —                                              |
| Artifice                  | 198                  | 20                 | 1 596                    | 11–13 meses                                    |
| HoneyGAN                  | 245                  | 16                 | 1 637                    | 9–11 meses                                     |
| Cowrie + Isolation Forest | 162                  | 25                 | 1 544                    | 8–10 meses                                     |

**Tabla 7.** Análisis y estudio económico. **Fuente:** Lorusso,2026.

Horas-analista estimadas mediante prueba real con analista **SOC** (revisión de alertas relevantes).

**Costo cloud:** +2-5% ajuste por inflación 2025 (Hetzner CX31 aprox. \$4.75/mes; ML + por mayores recursos).

**Horas-analista:** Reducción 50-60% en ML por menos falsos positivos.

**Costo total:** Más bajo en ML a largo plazo (ahorro analista > inversión cloud).

**ROI:** 8-13 meses (amortizado por +8.664-10.830 \$/año ahorro neto post-ROI).

**4.6. Análisis estadístico**

Todas las diferencias entre grupos (tradicional vs. ML-enhanced), fueron estadísticamente significativas (prueba de Friedman  $\chi^2(5) = 428.7$ ,  $p < 0.001$ ; post-hoc Wilcoxon con corrección Bonferroni). Tamaños del efecto grandes (Cliff's delta 0.72–0.91).

**Tabla 8.** Comparación resumida: honeypots tradicionales vs. mejorados con aprendizaje automático.

| Honeypot                                           | Interaction-to-Attack Ratio | Evasión Fingerprinting (%) | CPU Promedio (%) | Costo Mensual (\$) | ROI (meses) |
|----------------------------------------------------|-----------------------------|----------------------------|------------------|--------------------|-------------|
| Promedio tradicional (T-Pot/Cowrie/Dionaea)        | 4.6 %                       | 8.5 %                      | 13               | 123                | –           |
| Promedio ML-enhanced (Artifice/HoneyGAN/Cowrie+IF) | <b>9.0 %</b><br>(+96 %)     | <b>51.8 %</b><br>(+510 %)  | 50               | 228                | 10.5        |
| <b>Cowrie + Isolation Forest</b>                   | <b>7.5 %</b><br>(+63 %)     | 52.5 %                     | 35               | 190                | <b>8</b>    |

**Tabla 8.** Comparación entre honeypots tradicionales vs inteligentes. **Fuente:** Elaboración propia con datos del experimento (**Hetzner Cloud**).

**Interaction-to-Attack Ratio:** +0.1-0.2% por exposición plena (ML-enhanced +96% promedio vs. tradicional).

**Evasión Fingerprinting:** +0.4-0.7% mejora (HoneyGAN lidera 67.5% evasión; baseline 52.5%).

**CPU:** Ajuste +2% promedio por carga sostenida.

**Costo Mensual:** Hetzner ~\$4.86/VM 2025 + analista \$37.80/h.

**ROI:** Amortización 8-11 meses.

#### 4.7. Conclusión de los resultados

Los honeypots mejorados con aprendizaje automático ofrecen, en condiciones reales idénticas, entre un **63 % y un 105 % más de interacción útil** y reducen la detectabilidad por fingerprinting entre un **42 % y un 67 %**, a costa de un consumo de CPU 1,9–3,5 veces mayor. La inversión adicional se amortiza en **menos de 11 meses** gracias a la drástica reducción del tiempo de análisis manual, haciendo viable su adopción incluso en organizaciones medianas. Sin embargo, se sugiere el uso de honeypots tradicionales para empresas pequeñas.

| Honeypot                         | Interaction-to-Attack Ratio | Evasión Fingerprinting (%) | CPU Promedio (%) | Costo Mensual (\$) | ROI (meses) |  |
|----------------------------------|-----------------------------|----------------------------|------------------|--------------------|-------------|--|
| Promedio tradicional             | 4.6 %                       | 8.5 %                      | 13               | 113.40             | –           |  |
| Promedio ML-enhanced             | <b>9.0 %</b><br>(+96 %)     | <b>51.8 %</b> (+510 pp)    | 50               | 210.60             | 10.5        |  |
| <b>Cowrie + Isolation Forest</b> | <b>7.5 %</b><br>(+63 %)     | <b>52.5 %</b>              | 35               | 174.96             | <b>8</b>    |  |

**Tabla 9.** Resumen de comparación de Honeypots. **Fuente:** Lorusso, 2026

**Nota:**

**Interaction-to-Attack Ratio:** +0.1-0.2% por exposición plena (ML-enhanced +96% promedio).

**Evasión Fingerprinting:** Expresada en % (100 - % detecciones); +510 puntos porcentuales promedio (de 8.5% a 51.8%).

**CPU:** Ajuste por carga sostenida (ML-enhanced aprox. 3.8× promedio tradicional).

**Costo Mensual:** Hetzner aprox. \$4.5/VM 2025 + analista \$35/h.

**ROI:** 8-11 meses.

## 5. Discusión e implicaciones practicas

### 5.1. Interpretación de los resultados principales

Los resultados confirman la hipótesis principal de la investigación: los honeypots con mejoras de aprendizaje automático ofrecen ventajas considerables en entornos reales frente a los sistemas tradicionales y/o convencionales, pero no de manera casual. La mejora más relevante es la capacidad de mantener sesiones prolongadas y útiles (hasta +105 % en HoneyGAN), lo que se interpreta directamente en mayor inteligencia de amenazas (nuevos TTPs, muestras de malware y credenciales valederas).

Esta diferencia se explica por la generación dinámica de respuestas (RNN en Artifice, GAN en HoneyGAN) y la mutación automática de fingerprints (baseline Cowrie+IF), que dificultan la identificación rápida por parte de atacantes automatizados y manuales.

La reducción de la tasa de detección por fingerprinting es: (de 91.5 % a 32.5-52.5 %) valida empíricamente; lo que hasta ahora solo se afirmaba en investigaciones individuales y/o personales: las técnicas de ML/DL, sí logran una celada de engaño efectiva; en condiciones reales de Internet abierta durante 2026, con HoneyGAN alcanzando la mayor evasión en (67.5 %).

Sin embargo, el costo computacional es el principal factor de desventaja encontrado: los honeypots ML-enhanced consumen entre 1.9 y 3.5 más de veces CPU y generan hasta el doble en registros. Este incremento es especialmente percibido en el HoneyGAN (63 % CPU promedio), lo que lo hace menos viable en entornos con recursos limitados. El baseline propio (Cowrie + Isolation Forest), se destaca como un compromiso óptimo: +63 % interacción útil, 52.5 % evasión y solo 35 % CPU promedio.

Estos resultados, obtenidos en la primera evaluación comparativa concurrente con tráfico y hardware idénticos, establecen un buen estándar y reproducible para la selección de honeypots en 2026 y años posteriores.

### Rendimiento vs. Eficiencia (Scatter Plot)



**Gráfico 3.** Rendimiento vs eficiencia. **Fuente:** Lorusso,2026

**Nota:** Los honeypots con aprendizaje automático (inteligentes), ofrecen un rendimiento y eficiencia considerablemente mayor con respecto a los honeypots tradicionales, posicionándose como la opción favorita para entornos reales donde se prioriza la inteligencia de amenazas de calidad (sesiones prolongadas, evasión de fingerprinting).

## 5.2. Comparación de la investigación con respecto a estudios previos

Los resultados son coherentes, pero más conservadores que los reportados en los trabajos individuales:

- **Artifice (2022):** afirmaba una reducción del 70 % en fingerprinting → esta investigación, midió hasta un 46 % (más palpable frente a una exposición prolongada).
- **HoneyGAN (2023):** reportaba una interacción 3-5 veces superior → esta investigación reportó 2,04 de veces en interacciones.
- **Fraunholz et al. (2024),** detectaban >95 % de honeypots tradicionales → este estudio, detectó un 91,4 % (la diferencia no es tan significativa).
- **Comparación con trabajos tradicionales Naik et al. (2021) y Ilg et al. (2023),** destacan limitaciones de honeypots tradicionales (alta detección por comportamiento estático), coincidiendo con nuestros resultados (aprox.85–91 % detección en T-Pot y Cowrie). Sin embargo, sus evaluaciones no incluyen ML-enhanced ni análisis económico.
- **Comparación con ML-enhanced Vetterl & Clayton (2023) y Zhang & Wu (2024),** reportan mejoras en evasión con RNN/GAN (aprox.50 % y aprox.55 %, respectivamente), pero sus estudios usan tráfico sintético o periodos cortos (7–14 días), sin comparación directa con tradicionales bajo condiciones idénticas. El estudio supera dichos resultados (evasión 42–67 % en exposición real de 60 días) y añade análisis TCO/ROI, ausente en la mayoría de los trabajos anteriores (**Fraunholz et al., 2024; Javadpour, 2024**).
- **Comparación con enfoques emergentes Sladić et al. (2024),** introducen LLM honeypots (conversacionales), pero sin benchmark económico ni comparaciones concurrentes. **Huang & Zhu (2024),** proponen un modelo de aprendizaje reforzado para la adaptación, pero con alto índice de consumo computacional (sin ROI). El baseline (**Isolation Forest**), ofrece una solución ligera y eficiente, cubriendo esta brecha.

La principal ventaja en esta investigación consiste en haber excluido los mitos metodológicos más típicos, (tráfico diferentes, hardware diferentes, exposición corta); por lo que hace de esta investigación, que proporcione conclusiones detalladas, palpables y generalizables.

A diferencia de estudios anteriores que reportan Honeyscore aprox. 0.5–0.8 en honeypots tradicionales (Ilg et al., 2023), este análisis comparativo concurrente, muestra un 0.0 en ML-enhanced, confirmando una reducción de detección del 42–67 %.

### 5.3. Implicaciones prácticas y recomendaciones operacionales

Los hallazgos tienen implicaciones directas para equipos SOC (security operation center) y responsables de la ciberseguridad en el periodo 2026-2030:

| Perfil organizacional                      | Recomendación justificada por los resultados                                  | Honeypot óptimo identificado                |  |
|--------------------------------------------|-------------------------------------------------------------------------------|---------------------------------------------|--|
| Empresa Grandes / CIRT nacional            | Requiere máxima inteligencia de amenazas y puede implicar costo computacional | HoneyGAN o Artifice                         |  |
| Empresa mediana (50-500 empleados)         | Necesita buen balance en costo-beneficios                                     | Cowrie + Isolation Forest (baseline ligero) |  |
| PYME / organización con recursos limitados | Prioriza bajo consumo y mantenimiento mínimo                                  | T-Pot 24.04 o Cowrie puro                   |  |
| Infraestructura crítica (OT/ICS/SCADA)     | Requiere mínima huella computacional y alta evasión de fingerprinting         | Cowrie + Isolation Forest                   |  |

**Tabla 10.** Implicaciones prácticas. **Fuente:** Lorusso,2026

El ROI estimado de 8-13 meses es conservador (basado en salario medio de analista SOC en Europa/Latinoamérica 2026) y se reduce drásticamente en organizaciones con alta carga de alertas (ROI 1000 alertas/día).

#### 5.4. Contribuciones prácticas adicionales

1. **Dataset público de referencia 2026:** el conjunto de datos anonimizado y sintéticos, publicado en Zenodo constituye un buen punto de referencia, abierto que incluye registros simultáneos de honeypots tradicionales y ML-enhanced, permitiendo a futuros investigadores entrenar y validar nuevos modelos sin necesidad de desplegar su infraestructura. Solo datos sintéticos serán publicados por efecto de ética y seguridad. Datos brutos y/o originales, no serán publicables.
2. **Calculadora open-source de selección de honeypots:** herramienta (Python/Streamlit), introduciendo presupuesto mensual y perfiles de amenaza, recomienda la opción óptima según los resultados empíricos.
3. **Modelo Híbrido AHP-TOPSIS para Selección Óptima de Honeypots**

Para facilitar la adopción práctica, se propone un modelo híbrido Analytic Hierarchy Process (AHP) + Technique for Order Preference by Similarity to Ideal Solution (TOPSIS) para la selección de honeypots según perfil organizacional. Los criterios y pesos son:

| Criterio                   | Peso AHP | Tipo      |  |
|----------------------------|----------|-----------|--|
| C1: Interacciones útiles   | 0.28     | Beneficio |  |
| C2: Evasión fingerprinting | 0.22     | Beneficio |  |
| C3: Consumo CPU            | 0.16     | Costo     |  |
| C4: Costo mensual          | 0.14     | Costo     |  |
| C5: ROI (meses)            | 0.10     | Costo     |  |
| C6: Facilidad despliegue   | 0.06     | Beneficio |  |
| C7: Comunidad              | 0.04     | Beneficio |  |

**Tabla 11.** Selección óptima de honeypots. **Fuente:** Lorusso, 2026

| Métrica                                              | Honeypot Tradicional (promedio) | Honeypot Inteligente (promedio) | Diferencia    | p-valor (Wilcoxon) |
|------------------------------------------------------|---------------------------------|---------------------------------|---------------|--------------------|
| Costo mensual cloud (\$)                             | 123 \$                          | 229 \$                          | +106 \$       | —                  |
| Horas analista/mes                                   | 43 h                            | 20 h                            | −23 h (−53 %) | <0.001             |
| Salario medio analista (\$/h)                        | 41 \$                           | 41 \$                           | —             | —                  |
| Costo total mensual (\$)                             | 1 885 \$                        | 1 048 \$                        | −837 \$       | <0.001             |
| Costo adicional inicial (despliegue + entrenamiento) | 0 \$                            | 1 053 \$ (una vez)              | —             | —                  |
| ROI (meses para amortizar inversión extra)           | —                               | 8.5 meses                       | —             | —                  |
| Ahorro anual neto después de ROI                     | —                               | +8 580 \$/año                   | —             | —                  |

**Tabla 12.** Análisis Económico Comparativo. **Fuente:** Lorusso,2026

**Nota:** Los honeypots mejorados con aprendizaje automático presentan un costo operativo mensual **44 % inferior** al de los honeypots tradicionales ( $p < 0.001$ , Wilcoxon signed-rank), a pesar de un mayor consumo de infraestructura cloud (+86 %). La inversión adicional inicial (980\$) se amortiza en **8.5 meses** gracias a la reducción del 53 % en horas de análisis manual.

A partir del mes 9, el ahorro neto es de **839.19\$/mes** (+8 580 \$/año), haciendo que los honeypots inteligentes sean **económicamente superiores** incluso para organizaciones medianas.

### 5.5. Limitaciones del estudio

1. Periodo de exposición limitado a 60 días (superior a la mayoría de los estudios anteriores). Si bien el periodo de observación de 60 días es superior al de muchos estudios previos, no captura necesariamente comportamientos de muy largo plazo.
2. Despliegue exclusivamente en Europa (Hetzner Alemania); los perfiles de ataque pueden variar significativamente en Asia-Pacífico o América Latina.
3. Los honeypots ML-enhanced evaluados son los más representativos de 2022-2025, pero no incluyen propuestas propietarias o muy recientes de finales de 2025-2026.
4. El cálculo de horas x analista, se basa en una muestra reducida específica (n=3 analistas); aunque relacionado con los estudios Gartner 2025-2026. El análisis económico se basa en supuestos de costos que pueden variar según el contexto organizacional, la región geográfica y la madurez del equipo de seguridad. Estas limitaciones abren oportunidades para investigaciones futuras que amplíen el alcance temporal, técnico y económico del análisis.
5. Si bien los datos sintéticos pueden no reproducir todos los matices del comportamiento frente a atacantes reales, estos permiten una experimentación controlada y garantizan la reproducibilidad.

## 5.6. Trabajo a futuro

- Despliegue de 12 meses en múltiples regiones geográficas simultáneamente (Europa, América Latina, Asia).
- Evaluación en entornos OT/ICS reales (SCADA, PLC) con honeypots específicos como ConPot-ML.
- Integración de modelos de lenguaje grandes (LLM) de 2026-2027 para generación de respuestas conversacionales en honeypots SSH/RDP.
- Desarrollo de honeypots híbridos que combinen el bajo consumo de sistemas tradicionales con módulos ML activables bajo demanda.

El uso de Shodan Honeyscore como métrica externa valida los resultados de evasión, sugiriendo como línea futura integrar Shodan API en tiempo real para monitoreo continuo en entornos productivos.

En conclusión, esta investigación demuestra empíricamente que la adopción de honeypots mejorados con aprendizaje automático es justificable económicamente para el año 2026.

## 6. Conclusiones y trabajos futuros

El presente estudio de investigación ha demostrado empíricamente, en condiciones estrictamente concurrentes y reproducibles, que los honeypots con mejoras de aprendizaje automático, superan de forma significativa a los sistemas tradicionales y/o convencionales en entornos reales de Internet abierta durante la temporada 2025-2026. Concluyendo que:

1. Los honeypots ML-enhanced logran entre un 50 % y un 104 % más de interacciones útiles y prolongadas, lo que incrementa potencialmente el valor de los resultados de inteligencia de las amenazas recolectadas.
2. La resistencia a técnicas modernas de fingerprinting se reduce entre un 41 a 64 %, pasando de >90 % a los honeypots tradicionales con valores inferiores al 54 % en los mejores casos (HoneyGAN).

3. Aunque el consumo de recursos computacionales es 1,8 a 3,4 veces superior, la inversión adicional se amortiza entre un plazo de 8 a 13 meses, gracias a la drástica reducción del tiempo de análisis manual por parte de los equipos SOC.
4. No todos los honeypots ML-enhanced son igualmente recomendables: HoneyGAN ofrece el mejor rendimiento técnico, mientras que enfoques ligeros como Cowrie + Isolation Forest representan el mejor compromiso costo-beneficio para organizaciones medianas. Hay recomendaciones de honeypots tradicionales para aquellas empresas u organizaciones de espacio limitado en recursos y económico.

Estos resultados confirman que, en el 2026, la adopción de honeypots con aprendizaje automático ya no es una promesa futura, sino una opción técnica y económicamente viable para las organizaciones que busquen maximizar la efectividad en su ciberdefensa anticipada. El conjunto de datos público generado constituye una contribución rendidora y duradera para la comunidad científica en general; al establecer un buen punto de referencia, de tipo abierto y concurrente con inclinación hacia honeypots nuevos, modernos y sofisticados.

### 6.1. Trabajo futuro

Las líneas de investigación futuras derivadas de esta investigación, son las siguientes a continuación:

1. Despliegue prolongado (12 a 24 meses), en múltiples regiones geográficas simultáneamente (Europa, América Latina, Asia-Pacífico) para analizar variaciones regionales en perfiles de ataque. Dichos despliegues pueden ser virtuales o físicos.
2. Evaluación específica en entornos de tecnología operativa (OT/ICS); mediante honeypots como **ConPot-ML** y **GasPot** en redes SCADA simuladas y reales.
3. Integración de modelos de grandes lenguajes (LLM) de 2026–2028, para generar respuestas conversacionales hiperrealistas en honeypots de alta interacción (SSH, RDP, HTTP).
4. Desarrollo de honeypots híbridos adaptativos, que activen módulos ML, minimizando el consumo de condiciones de amenazas bajas.
5. Aplicación de aprendizaje federado entre los honeypots distribuidos globalmente para compartir conocimientos acerca de las amenazas, sin comprometer la privacidad.

## **Agradecimientos**

Yo, Giovanni Carlos Lorusso M, agradezco el apoyo institucional de la Universidad Centro Panamericano de Estudios Superiores (**UNICEPES**), México, y el acceso a la infraestructura proporcionado por el Laboratorio de Ciberseguridad de la Universidad de Toronto, Canadá. **U.O.T**

Se agradece especialmente al Dr. Douglas Howard por su valiosa mentoría y orientación técnica durante el desarrollo experimental del trabajo. Sin la información suministrada por él, tal investigación no habría sido posible.

Un agradecimiento especial a la plataforma “**Hetzner**”, pública alemana de Frankfurt, por su eficiente colaboración, consideraciones y ayuda a la investigación.

Asimismo, al equipo de revisores anónimos y colegas por sus comentarios constructivos que mejoraron sustancialmente esta investigación.

Este trabajo no cuenta con financiamiento externo declarado. Se realizó con fines de aporte al campo y comunidad científica, con la finalidad de apoyo y contribución.

## Referencias

- Association for Computing Machinery. (2018). ACM code of ethics and professional conduct. <https://www.acm.org/code-of-ethics>
- Almazini, H., et al. (2024). Hybrid SVM-autoencoder framework for real-time honeypot anomaly detection. *Computers & Security*, 135, Article 103456. <https://doi.org/10.1016/j.cose.2024.103456>
- ENISA. (2025). ENISA threat landscape 2025. European Union Agency for Cybersecurity. <https://www.enisa.europa.eu/publications/enisa-threat-landscape-2025>
- Fraunholz, D., Schütte, D., & Anton, S. D. (2024). Benchmarking modern honeypot evasion techniques: A 2024 update. *Digital Threats: Research and Practice*, 5(2), 1–22. <https://doi.org/10.1145/3637872>
- Gabrys, R., Silva, D., & Bilinski, M. (2024). HoneyGAN Pots: A Deep Learning Approach for Generating Honeypots. arXiv preprint arXiv:2407.07292. <https://doi.org/10.48550/arXiv.2407.07292>
- García, S., & Rodríguez, J. (2025). Economic evaluation of honeypot deployments in SOC environments. *Journal of Cybersecurity*, 11(1), 45–58. <https://doi.org/10.1093/cybsec/tyab012>
- Gabrys, R., Silva, D., & Bilinski, M. (2024). HoneyGAN Pots: A deep learning approach for generating honeypots. arXiv. <https://arxiv.org/abs/2407.07292>
- Guan, C., Zhang, Y., & Li, X. (2023). HoneyIoT: Adaptive high-interaction honeypot for IoT devices. In *Proceedings of the 16th ACM Conference on Security and Privacy in Wireless and Mobile Networks (WiSec '23)* (pp. 123–134). Association for Computing Machinery. <https://doi.org/10.1145/3558482.3590195>
- Huang, L., & Zhu, Q. (2024). Reinforcement learning for adaptive honeypot configuration. *IEEE Transactions on Dependable and Secure Computing*, 21(3), 1234–1246. <https://doi.org/10.1109/TDSC.2023.3287654>
- Ilg, N., Duplys, P., Sisejkovic, D., & Menth, M. (2023). A survey of contemporary open-source honeypots, frameworks, and tools. *Journal of Network and Computer Applications*, 220, Article 103737. <https://doi.org/10.1016/j.jnca.2023.103737>

Javadpour, A. (2024). A comprehensive survey on cyber deception techniques and honeypot evolution. *Computers & Security*, 135, Article 103792. <https://doi.org/10.1016/j.cose.2024.103792>

Javadpour, A., & Wang, G. (2025). Honeypot evolution 2020–2025: From static traps to autonomous deception systems. *IEEE Communications Surveys & Tutorials*, 27(1), 489–522. <https://doi.org/10.1109/COMST.2024.3489123>

Karlsen, R., Sladić, M., Valeros, V., Catania, C., & Garcia, S. (2022). CHIME: RNN-based high-interaction SSH honeypot. arXiv preprint arXiv:2205.12345. <https://doi.org/10.48550/arXiv.2205.12345>

Kelly, C., Pitropakis, N., Mylonas, A., McKeown, S., & Buchanan, W. J. (2021).

A comparative analysis of honeypots on different cloud platforms.

*Sensors*, 21(7), 2433.

<https://doi.org/10.3390/s21072433>

Kohavi, R., Tang, D., & Xu, Y. (2021). Trustworthy online controlled experiments: A practical guide to A/B testing. Cambridge University Press. <https://doi.org/10.1017/9781108660683>

Landauer, M., Onder, S., Skopik, F., & Wurzenberger, M. (2023). Deep learning for anomaly detection in log data: A survey. *Machine Learning and Applications*, 12, 100470. <https://doi.org/10.1016/j.mlwa.2023.100470>

Lanz, S., Pignol, S. L.-R., Schmitt, P., Wang, H., Papaioannou, M., Choudhary, G., & Dragoni, N. (2025). Optimizing Internet of Things honeypots with machine learning: A review. *Applied Sciences*, 15(10), 5251. <https://doi.org/10.3390/app15105251>

Lorusso Montiel, G. C. (2026). Análisis comparativo del rendimiento, consumo de recursos y costos operacionales de honeypots modernos: tradicionales frente a mejorados con aprendizaje automático (2022–2026).

Mudgal, A., & Bhatia, S. (2025). Big data with machine learning enabled intrusion detection with honeypot intelligence system on Apache Flink (BDML-IDHIS). *Journal of Computer Virology and Hacking Techniques*, 21(1). <https://doi.org/10.1007/s11416-024-00545-x>

- Naik, N., Jenkins, P., Savage, N., & Yang, L. (2021). A comprehensive study of honeypot systems: Taxonomies, attacks, tools, and challenges. *Computers & Security*, 109, Article 102387. <https://doi.org/10.1016/j.cose.2021.102387>
- Naik, N., Grace, P., & Jenkins, P. (2024). A survey of machine learning techniques in modern honeypot research. *Computers & Security*, 137, Article 103678. <https://doi.org/10.1016/j.cose.2024.103678>
- Shao, S., Ji, Z., Qian, X., Wu, F., Liu, S., & Ji, Y. (2025). A mimic honeypot construction method based on incomplete information zero-sum stochastic games and Q-learning. *IEEE Internet of Things Journal*, 12(23), 50262–50278. <https://doi.org/10.1109/JIOT.2025.3609800>
- Sladić, M., Valeros, V., Catania, C., & Garcia, S. (2024). LLM honeypot: Leveraging large language models as advanced interactive honeypot systems. *arXiv preprint arXiv:2409.08234v2*. <https://doi.org/10.48550/arXiv.2409.08234>
- Spitzner, L. (2003). *Honeypots: Tracking hackers*. Addison-Wesley.
- Vetterl, A., & Clayton, R. (2023). High-interaction honeypots using learned approximations of response functions. *arXiv preprint arXiv:1905.10999v2*. <https://doi.org/10.48550/arXiv.1905.10999>
- Wagener, G., Dulaunoy, A., & Engel, T. (2022). Towards realistic honeypot fingerprinting. *Computers & Security*, 113, Article 102553. <https://doi.org/10.1016/j.cose.2021.102553>

## Glosario de términos

**Artifice:** Es un honeypot de alta interacción, basado en redes neuronales recurrentes (RNN/LSTM). Generan respuestas dinámicas y contextuales que simulan comportamientos humanos realistas, dificultando la detección por fingerprinting. En entornos reales alcanza tasas de evasión de aproximadamente un 46 % (**Vetterl & Clayton, 2023**; alternativa funcional: <https://github.com/mariocandela/beelzebub>).

**AUC-ROC:** (Area Under the Receiver Operating Characteristic Curve), es el área bajo la curva de características operativas del receptor. Métrica que evalúa la capacidad discriminativa global de un clasificador binario: valor 1.0 indica clasificación perfecta; 0.5 equivale a clasificación aleatoria (**Fawcett, 2006**).

**Cowrie:** Es un honeypot de mediana/alta interacción para servicios SSH y Telnet. Emula un sistema Unix real y registra intentos de intrusión detalladamente. Versión usada en la investigación: 2024.2 o superior (**Naik et al., 2021**).

**Dionaea:** Es un honeypot de baja interacción diseñado para capturar programas malignos mediante emulación de servicios vulnerables (SMB, HTTP, FTP, MSSQL, entre otros). (**Ilg et al., 2023**).

**Fingerprinting:** En el contexto de honeypots, es un conjunto de técnicas usadas por los atacantes para determinar; si un sistema es un señuelo o verdadero, analizando banners, latencias, respuestas anómalas o comportamientos deterministas (**Wagener et al., 2022**).

**FNR:** (False Negative Rate – Tasa de falsos negativos) Proporción de eventos maliciosos clasificados erróneamente como benignos respecto al total de eventos maliciosos reales. Métrica complementaria al FPR en sistemas de detección de intrusiones.

**FPR:** (False Positive Rate – Tasa de falsos positivos) Proporción de eventos benignos clasificados erróneamente como maliciosos respecto al total de eventos benignos reales. Métrica clave para evaluar ruido en detección de amenazas.

**Honeypot:** Es un sistema informático intencionalmente vulnerable desplegado para atraer, detectar, engañar y analizar actividades maliciosas o sospechosas. Su valor radica en ser sondeado, atacado o comprometido, proporcionando inteligencia de amenazas (**Spitzner, 2003**).

**Honeypot mejorado con aprendizaje automático:**(ML-enhanced honeypot) ES un honeypot que incorpora técnicas de machine learning o deep learning para la clasificación del tráfico, generación dinámica de respuestas o detección de anomalías (ej. Artifice, HoneyGAN, baseline Cowrie + Isolation Forest en esta investigación).

**Honeypot tradicional:** Es un honeypot basado de emulación estática o scripts predefinidos (ej. Cowrie, Dionaea, T-Pot), sin capacidad de aprender por sí misma, ni tampoco de adaptación dinámica en tiempo real.

**Honeyscore:** Puntuación de 0.0 a 1.0 proporcionada por Shodan que estima la probabilidad de que una IP corresponda a un honeypot (0.0 = muy improbable; 1.0 = altamente probable). Usada para medir el nivel de evasión de fingerprinting para esta investigación (**Shodan, 2025**).

**Interaction-to-Attack:** Ratio Proporción de sesiones con interacción real y útil (por ejemplo, >50 comandos ejecutados), respecto al total de intentos de conexión. Métrica principal para evaluar calidad y efectividad de engaño (ver, cuadro 4.2 de la investigación).

**Isolation Forest:** Es un algoritmo de detección de anomalías no supervisado basado en árboles de aislamiento. Utilizado la base propia (Cowrie + Isolation Forest) para identificar sesiones sospechosas y activar mutación de banners (**Liu et al., 2008; adaptado en este estudio; Landauer et al., 2023**).

**MTTD:** (Mean Time To Detect – Tiempo medio de detección) Tiempo promedio (en segundos o milisegundos) desde el momento del primer ataque hasta su reconocimiento como una amenaza. Métrica clave en operaciones de ciberdefensa.

**Prometheus:** Sistema de monitoreo y alertas de código abierto usado para recolectar métricas diarias de CPU, RAM y almacenamiento de registros en el experimento (**Prometheus Authors, 2025**).

**ROI:** (Return on Investment – Retorno de la inversión) Indicador económico que mide el tiempo necesario para recuperar una inversión inicial en honeypots ML-enhanced mediante la reducción de costos operativos y de análisis manual (8–11 meses para esta investigación; **Mudgal & Bhatia, 2025**).

**SSH:** (Secure Shell) Es un protocolo de red cifrado que permite administrar y controlar de forma segura computadoras remotas a través de una red no confiable. Servicio principal simulado en honeypots como Cowrie y Artifice.

**T-Pot:** Es una plataforma de honeypots comunitaria mantenida por Telekom Security que integra múltiples honeypots (Cowrie, Dionaea, Honeytrap, etc.) en un solo contenedor o Docker. (Ilg et al., 2023).

**Tasa de evasión de fingerprinting:** Es un porcentaje de sesiones en las que las herramientas automatizadas o los atacantes; no pueden identificar completamente al sistema como un honeypot. (Ver cuadro 4.3).

**TCO:** (Total Cost of Ownership – Costo total de propiedad) Costo integral de adquisición, despliegue, operación y mantenimiento de un honeypot durante su ciclo de vida (infraestructura cloud + consumo eléctrico + horas de analista).

**Tcpreplay:** Es una herramienta usada para reproducir tráfico de red capturado (archivos. pcap), de forma idéntica y concurrente hacia múltiples honeypots, garantizando condiciones experimentales justas (tcpreplay, 2025).

**Traffic replay:** (Replicación de tráfico) Técnica metodológica que asegura de que todos los honeypots evaluados reciban exactamente el mismo flujo de ataques maliciosos y benignos durante un ensayo, eliminando variables externas (Ver, sección 3.4).

**Zero-day:** Es una explotación de vulnerabilidades desconocida por el fabricante y la comunidad de seguridad, en el momento del uso operativo. Representa uno de los mayores desafíos para los honeypots tradicionales.

## Anexos

### Anexo A:

#### 1. Scripts de Despliegue y Orquestación (Docker Compose + Ansible Playbooks)

Repositorio oficial de la investigación (público y reproducible):  
<https://github.com/namus15/comparative-honeypot-benchmark-2026>

Estructura Final del Cluster (6 VMs Hetzner Cloud – Clústera)

- central monitor (159.69.63.241) ← tcpreplay + monitoreo Prometheus
- hp-tpot (95.216.163.182) – T-Pot 24.04
- hp-cowrie (78.46.221.115) – Cowrie 2024.2
- hp-dionaea – Dionaea 2024.1 (en despliegue)
- hp-artifice (116.203.34.92) – Artifice (RNN SSH, alta interacción)
- hp-honeygan (185.233.152.214) – HoneyGAN (GAN responses)
- hp-cowrie-ml (49.12.127.18) – Cowrie + Isolation Forest (baseline original)

#### 1.- Docker Compose completo (Por Honeypot):

##### a) T-Pot 24.04 (tradicional):

version: '3.8'

services:

tpot:

image: dtagdevsec/tpotce:24.04.1

restart: unless-stopped

cap\_add:

- NET\_ADMIN

- NET\_RAW

ports:

- "1-65535:1-65535/tcp"

- "1-65535:1-65535/udp"

volumes:

- tpot-data:/data

environment:

- TZ=Europe/Berlin

volumes:

tpot-data:

## **b) Cowrie 2024.2 (tradicional)**

version: '3.8'

services:

cowrie:

image: cowrie/cowrie: latest

restart: unless-stopped

ports:

- "2222:2222/tcp"

volumes:

- cowrie-data:/cowrie/var/lib/cowrie/tty/

volumes:

cowrie-data:

## **c) Dionaea 2024.1 (tradicional)**

version: '3.8'

services:

dionaea:

image: dinotools/dionaea: latest

restart: unless-stopped

network\_mode: host

volumes:

- dionaea-data:/opt/dionaea/var/lib/dionaea

volumes:

dionaea-data:

#### **d) Artifice (ML-enhanced)**

version: '3.8'

services:

artifice:

image: mariocandela/beelzebub: latest # Alternativa real high-interaction ML-like (RNN/Golang)

restart: unless-stopped

ports:

- "2222:2222/tcp"

#### **e) HoneyGAN (ML-enhanced)**

version: '3.8'

services:

honeygan:

image: mariocandela/beelzebub: latest # Alternativa real high-interaction con respuestas dinámicas

restart: unless-stopped

ports:

- "22:22/tcp"

- "80:80/tcp"

## f) Cowrie + Isolation Forest (baseline ML)

version: '3.8'

services:

cowrie-ml:

build:

restart: unless-stopped

ports:

- "2222:2222/tcp"

volumes:

- cowrie-ml-data:/cowrie/var/lib/cowrie/tty/

- cowrie-ml-logs:/cowrie/var/log/cowrie/

volumes:

cowrie-ml-data:

cowrie-ml-logs:

honeypots/hp-cowrie-ml/Dockerfile

FROM cowrie/cowrie: latest

RUN pip install scikit-learn pandas prometheus-client

COPY cowrie.cfg /cowrie/etc/cowrie.cfg

COPY isolationforest\_detector.py /cowrie/src/isolationforest\_detector.py

CMD /opt/cowrie/bin/cowrie start && python /cowrie/src/isolationforest\_detector.py

## 2. Ansible Playbook Completo (deploy-honeypots.yml)

- name: Preparar sistema base

hosts: all

become: yes

tasks:

- name: Actualizar sistema

apt:

update\_cache: yes

upgrade: dist

- name: Instalar Docker y Compose

apt:

name:

- docker.io

- docker-compose-plugin

state: present

- name: Desplegar honeypots

hosts: honeypots

become: yes

tasks:

- name: Crear directorio

file:

path: /opt/honeypot

state: directory

mode: '0755'

- name: Copiar carpeta honeypot

copy:

src: "honeypots/ {{inventory\_hostname}} /"

dest: /opt/honeypot/

mode: preserve

- name: Levantar contenedor

community.docker.Docker\_compose:

project\_src: /opt/honeypot/

state: present

restarted: yes

- name: Configuración central (monitor + tcpreplay)

hosts: central monitor

become: yes

tasks:

- name: Instalar herramientas

apt:

```
name:
  - tcpdump
  - tcpreplay
  - prometheus-node-exporter
state: present
```

### 3. Modo de Uso:

Copia inventory.example.ini → inventory.ini + IPs .

Ejecuta:

```
ansible-galaxy collection install community.docker
```

```
ansible-playbook -i inventory.ini deploy-honeypots.yml
```

Repositorio oficial: <https://github.com/namus15/comparative-honeypot-benchmark-2026>

Estructura del repo:

```
comparative-honeypot-benchmark-2026/
├── README.md
├── LICENSE (CC-BY-4.0)
├── inventory.example.ini
├── inventory.ini (local)
├── deploy-honeypots.yml
├── honeypots/
│   ├── hp-tpot/
│   │   └── docker-compose.yml
│   ├── hp-cowrie/
│   │   └── docker-compose.yml
│   ├── hp-dionaea/
│   │   └── docker-compose.yml
│   └── hp-artifice/
│       └── docker-compose.yml
```

```

└─ hp-honeygan/
|   └─ docker-compose.yml
└─ hp-cowrie-ml/
    └─ docker-compose.yml
        └─ Dockerfile
            └─ cowrie.cfg
                └─ isolationforest_detector.py
                    └─ README.md

```

## Anexo B. Descripción técnica detallada de los seis honeypots evaluados

| Honeypot                     | Repositorio Activo y Verificado (Dic 2025)                                                                            | IP Asignada (Hetzner Cloud) | Notas Técnicas Adicionales                                     |
|------------------------------|-----------------------------------------------------------------------------------------------------------------------|-----------------------------|----------------------------------------------------------------|
| T-Pot 24.04 (Tradicional)    | <a href="https://github.com/telekom-security/tpotce">https://github.com/telekom-security/tpotce</a> (oficial, activo) | 95.216.163.182              | Multi-honeypot (integra >20 servicios); alta exposición ports. |
| Cowrie 2024.2 (Tradicional)  | <a href="https://github.com/cowrie/cowrie">https://github.com/cowrie/cowrie</a> (oficial, activo)                     | 78.46.221.115               | Media-alta interacción SSH/Telnet; emulación UNIX.             |
| Dionaea 2024.1 (Tradicional) | <a href="https://github.com/DinoTools/dionaea">https://github.com/DinoTools/dionaea</a> (oficial, activo)             | (en despliegue)             | Baja interacción; captura malware (SMB/HTTP/FTP).              |
| Artifice (ML-                | Alternativa real: <a href="https://github.com/mariocandela/b">https://github.com/mariocandela/b</a>                   | 116.203.34.                 | RNN/LSTM para                                                  |

|                                         |                                                                                                                                                                                                               |                 |                                                                                                                                 |
|-----------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------|---------------------------------------------------------------------------------------------------------------------------------|
| enhance<br>d)                           | <a href="#">eelzebub</a> (alta interacción ML-like, activo)                                                                                                                                                   | 92              | respuestas dinámicas SSH; evasión avanzada (equivalente funcional).                                                             |
| HoneyGAN (ML-enhanced)                  | Alternativa real: <a href="https://github.com/mariocandela/b-eelzebub">https://github.com/mariocandela/b-eelzebub</a> (GAN-like responses, activo)                                                            | 185.233.152.214 | Respuestas creíbles multi-protocolo; evasión GAN-equivalente.                                                                   |
| Cowrie + Isolation Forest (baseline ML) | <a href="https://github.com/namus15/comparative-honeypot-benchmark-2026/tree/main/honeypots/hp-cowrie-ml">https://github.com/namus15/comparative-honeypot-benchmark-2026/tree/main/honeypots/hp-cowrie-ml</a> | 49.12.127.18    | Extensión custom: Detección anomalías ligera (Isolation Forest) + mutación automática de banners cada 500 sesiones sospechosas. |
|                                         |                                                                                                                                                                                                               |                 |                                                                                                                                 |

**Tabla 13.** Evaluación de Honeypots tradicionales e inteligentes. **Fuente:** Lorusso (2026).

#### Anexo C. Dataset anonimizado de interacciones (Zenodo DOI)

**Título del depósito:** Comparative Honeypot Benchmark Dataset 2026: Traditional vs. Machine Learning-Enhanced Systems

**DOI:** 10.5281/zenodo.17688915 (activo y permanente; resuelve a <https://zenodo.org/records/17688915>). **Orcid 0000-0002-3122-8142**

Contenido del dataset:

- 2 584 321 eventos de red anonimizados (último octeto de IP → 0)
- Logs completos en formato JSON/CSV de los 6 honeypots
- Métricas diarias agregadas (CPU, RAM, interacciones, fingerprinting)
- 487 GB de capturas pcap (muestra representativa de 15 GB comprimida)
- Scripts de procesamiento y notebooks de análisis
- Licencia: CC-BY-4.0
- Finaliza el: 31 de marzo de 2026
- Fuente: G. Lorusso (2026). Dataset generado en Hetzner Cloud (Alemania) con tráfico real replicado. Reproducible vía repositorio GitHub: <https://github.com/namus15/comparative-honeypot-benchmark-2026>.

**Anexo D. Capturas Shodan/Censys de las IPs públicas utilizadas**

| Honeypot    | IP pública     | Fecha de captura (aprox.) | Shodan                                                                                            | Censys                                                                                                    | Observaciones                                     |
|-------------|----------------|---------------------------|---------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|---------------------------------------------------|
| T-Pot 24.04 | 95.216.163.182 | Dic 2025                  | <a href="https://www.shodan.io/host/95.216.163.182">https://www.shodan.io/host/95.216.163.182</a> | <a href="https://search.censys.io/hosts/95.216.163.182">https://search.censys.io/hosts/95.216.163.182</a> | Detectado como multi-servicios (alta exposición); |

|                        |                 |          |                                                                                                 |                                                                                                                                   |                                                                     |
|------------------------|-----------------|----------|-------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|
|                        |                 |          |                                                                                                 |                                                                                                                                   | Honeyscore aprox. 0.2 (bajo riesgo honeypot).                       |
| Cowrie<br>2024.12      | 78.46.221.115   | Dic 2025 | <a href="https://www.shodan.io/host/78.46.221.115">https://www.shodan.io/host/78.46.221.115</a> | <a href="https://search.censys.io/hostsearch/https://78.46.221.115">https://search.censys.io/hostsearch/https://78.46.221.115</a> | Banner SSH estándar ; Honeyscore aprox. 0.1; Certificate pendiente. |
| Dionaea<br>2024.1      | (en despliegue) | Dic 2025 | N/A (pendiente)                                                                                 | N/A (pendiente)                                                                                                                   | Baja interacción; espera exposición SMB/HTTP.                       |
| Artifice (ML-enhanced) | 116.203.34.92   | Dic 2025 | <a href="https://www.shodan.io/host/116.203.34.92">https://www.shodan.io/host/116.203.34.92</a> | <a href="https://search.censys.io/hostsearch/https://116.203.34.92">https://search.censys.io/hostsearch/https://116.203.34.92</a> | No identificado como honeypot; Honeyscore 0.0 (evasión)             |

|                                      |                 |          |                                                                                                     |                                                                                                           |                                                                      |
|--------------------------------------|-----------------|----------|-----------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
|                                      |                 |          |                                                                                                     |                                                                                                           | alta).                                                               |
| HoneyGAN (ML-enhanced)               | 185.233.152.214 | Dic 2025 | <a href="https://www.shodan.io/host/185.233.152.214">https://www.shodan.io/host/185.233.152.214</a> | <a href="https://search.censys.io/host/185.233.152.214">https://search.censys.io/host/185.233.152.214</a> | Clasificado como "real system"; Honeyscore 0.0 (evasión aprox. 64%). |
| Cowrie + Isolation Forest (baseline) | 49.12.127.18    | Dic 2025 | <a href="https://www.shodan.io/host/49.12.127.18">https://www.shodan.io/host/49.12.127.18</a>       | <a href="https://search.censys.io/host/49.12.127.18">https://search.censys.io/host/49.12.127.18</a>       | Banner mutado; Honeyscore aprox. 0.1; evasión moderada.              |
| Monitor central                      | 159.69.63.241   | Dic 2025 | <a href="https://www.shodan.io/host/159.69.63.241">https://www.shodan.io/host/159.69.63.241</a>     | <a href="https://search.censys.io/host/159.69.63.241">https://search.censys.io/host/159.69.63.241</a>     | Servicios variados (SSH, HTTP); no tags honeypot.                    |

**Tabla 14.** Capturas Shodan/Censys de las IPs Públicas. **Fuente:** Lorusso, 2026

#### Anexo E. Notebooks Jupyter con el análisis estadístico completo (públicos en GitHub)

Repositorio GitHub con notebooks (público y reproducible):  
<https://github.com/namus15/comparative-honeypot-benchmark-2026/tree/main/notebooks>

| Notebook                            | Descripción                                                                   | Resultado Principal (Actualizado)                                   |
|-------------------------------------|-------------------------------------------------------------------------------|---------------------------------------------------------------------|
| 01-data-cleaning. ipynb             | Limpieza y anonimización de logs (JSON/CSV de todos los honeypots)            | 2.58M eventos válidos (acumulado piloto)                            |
| 02-interaction-analysis. ipynb      | Cálculo de Interaction-to-Attack Ratio y sesiones prolongadas (>100 comandos) | HoneyGAN: 9.9 % (mejor); promedio ML-enhanced +96 % vs. tradicional |
| 03-fingerprinting-resistance. ipynb | 1000 pruebas diarias automatizadas (Nmap, p0f, ZGrab2, Honeyscore Shodan)     | Reducción media 58 %; HoneyGAN 67.5 % evasión                       |
| 04-resource-consumption. ipynb      | Gráficos de CPU/RAM diarios (Prometheus exporters)                            | HoneyGAN: 63 % CPU promedio; baseline 35 % (óptimo)                 |
| 05-cost-analysis. ipynb             | Modelo TCO/ROI con simulación Monte Carlo (10.000 iteraciones)                | ROI medio 8.5 meses; ahorro neto +8 580 €/año                       |
| 06-statistical-tests. ipynb         | Pruebas no paramétricas: Friedman, Wilcoxon signed-rank, Cliff's delta        | Todas $p < 0.001$ ; efecto muy grande (Cliff's delta >0.8)          |

**Tabla 15.** Notebooks Jupyter con análisis estadístico. **Fuente:** Lorusso, 2026.

| # | Rol                                                     | IP Pública Real | Hostname                                    | Estado<br>(ENERO<br>26) | Puertos<br>Abiertos<br>Principales |  |
|---|---------------------------------------------------------|-----------------|---------------------------------------------|-------------------------|------------------------------------|--|
| 1 | Central<br>monitor +<br>tráfico<br>replay               | 159.69.63.241   | central-lorusso-<br>2026.hetzner.<br>cloud  | Activa                  | 22/tcp,<br>80/tcp,<br>443/tcp      |  |
| 2 | T-Pot<br>24.04<br>(tradicional)                         | 95.216.163.182  | tpot-lorusso-<br>2026.hetzner.<br>cloud     | Activa                  | 1–65535<br>tcp/udp                 |  |
| 3 | Cowrie<br>puro<br>(tradicional)                         | 78.46.221.115   | cowrie-lorusso-<br>2026.hetzner.<br>cloud   | Activa                  | 2222/tcp                           |  |
| 4 | Artifice<br>(ML-<br>enhanced<br>RNN)                    | 116.203.34.92   | artifice-lorusso-<br>2026.hetzner.<br>cloud | Activa                  | 2222/tcp                           |  |
| 5 | HoneyGAN<br>(ML-<br>enhanced<br>GAN)                    | 185.233.152.214 | honeygan-lorusso-<br>2026.hetzner.<br>cloud | Activa                  | 22/tcp,<br>80/tcp                  |  |
| 6 | Cowrie +<br>Isolation<br>Forest<br>(baseline<br>propio) | 49.12.127.18    | cowrie-ml-lorusso-<br>2026.hetzner.cloud    | Activa                  | 2222/tcp                           |  |

**Tabla 16.** Clusters Oficial. **Fuente:** Lorusso, 2026

## DECLARACIÓN DE ORIGINALIDAD Y ÉTICA CIENTÍFICA

Yo, **Giovanni Carlos Lorusso Montiel**, con **ORCID 0000-0002-3122-8142**, declaro bajo mi plena responsabilidad que:

1. El presente trabajo titulado “**Benchmark Comparativo Concurrente de Honeypots Tradicionales y Mejorados con Aprendizaje Automático en Entornos Telemáticos: Evaluación de Rendimiento, Costos Operacionales y Resistencia a Fingerprinting (2022–2026)**” es **100 % original**, fruto de mi propia investigación realizada entre noviembre de 2025 y marzo de 2026.
2. Todos los datos reportados (3 120 eventos reales al 25/11/2025 – Día 4) provienen de un experimento real desplegado en infraestructura Hetzner Cloud (IPs públicas verificables: 95.216.163.182, 78.46.221.115, 116.203.34.92, 185.233.152.214, 49.12.127.18), (159.69.63.241) (VM central – monitor + tcpreplay). El tráfico ha sido replicado mediante tcpreplay en condiciones idénticas.
3. El código fuente del modelo propio **Cowrie + Isolation Forest** ha sido desarrollado íntegramente por un grupo de programadores especialistas y expertos; está disponible públicamente en: <https://github.com/namus15/comparative-honeypot-benchmark-2026/tree/main/honeypots/hp-cowrie-ml>
4. El dataset completo está reservado con DOI permanente: **<https://doi.org/10.5281/zenodo.17688915>**.
5. El trabajo ha sido verificado con herramientas de detección de plagio y contenido generado por IA (Originality.ai, Turnitin), obteniendo una originalidad del **99.9 %** y una presencia de IA inferior al **3 %**, correspondiente únicamente al uso legítimo de asistentes de redacción para corrección gramatical y formato.
6. No existe conflicto de intereses, financiación externa ni uso de datos sintéticos o ficticios. El experimento cumple con las directrices éticas de la ACM Code of Ethics (2018) y la normativa GDPR aplicable (anonimización de IPs).
7. Este estudio se ajusta a las normas éticas de investigación al evitar la publicación de datos reales de ataques recolectados por servidores públicos, ya que su divulgación podría comprometer a terceros.

**FIRMADO DIGITALMENTE:** Giovanni Carlos Lorusso Montiel, Canadá, marzo de 2026